

Agentes Conversacionais Offline Baseados em SLMs

Navegação Assistiva de Apps para a Terceira Idade

Aluno: Marcos Paulo Arbex Guida | **Orientadora:** Dra. Marluce Rodrigues Pereira


Universidade Federal de Lavras (UFLA) — PCC557

A Barreira da Exclusão Digital

Interfaces gráficas mobile modernas geram **alta carga cognitiva** e ansiedade na população idosa.

Assistentes comerciais exigem **nuvem**, criando barreiras em planos de dados restritos ou ambientes isolados.

Edge AI: Execução local garante privacidade, latência previsível e custo zero de infraestrutura.



Objetivo e Arquitetura

O Desafio

Mapear comandos coloquiais e vagos (ex: "caderno de telefone") em ações estruturadas de navegação sem auxílio externo.

O Middleware

$$f(\text{Prompt}) \rightarrow \text{JSON}(\text{Ação}, \text{Destino})$$

Telas: medicamentos, contatos, compromissos, alarme e galeria.

Seleção de Modelos (Small Language Models)



Qwen-0.5B

0.5B Parâmetros

~380 MB RAM

Foco: Dispositivos legados e
baixíssimo consumo.



Gemma-2B

2.0B Parâmetros

~1.4 GB RAM

Equilíbrio entre hardware
intermediário e lógica.



Phi-3-mini

3.8B Parâmetros

~2.2 GB RAM

Baseline de alto desempenho
lógico (Microsoft).

Metodologia e Rigor Científico

 **Dataset Assistivo:** 15 prompts simulando linguagem humana real e termos analógicos.

 **Acurácia Estrita:** Exigência de JSON sintaticamente perfeito para o parser.

 **Acurácia Relaxada:** Avaliação da intenção semântica (mesmo com erros de sintaxe).

Restrição de Hardware


Teto rigoroso de **2 GB de RAM livre**, simulando smartphones de entrada ou dispositivos legados.

Benchmark Consolidado

Modelo	RAM	Latência Média	Acurácia Estrita	Acurácia Relaxada
Qwen-0.5B	~380 MB	1.49 s	0.00%	40.00%
Gemma-2B	~1.4 GB	2.33 s	26.67%	60.00%
Phi-3-mini	~2.2 GB	2.56 s	73.33%	86.67%

Trade-off: Hardware vs. Assertividade

Acurácia Semântica Relaxada (Capacidade de entender a intenção do idoso)



Nota: O aumento de parâmetros compensa exponencialmente em inteligência, mesmo com o custo de latência.

Análise de Patologias (Log de Erros)

Qwen: Colapso

Ecolalia e loops infinitos de alucinação. Incapaz de seguir instruções negativas.

Gemma: Meta-Programador

Tentou resolver o problema escrevendo scripts Python em vez de gerar o JSON.

Phi-3: Context Leaking. Gerava o JSON correto, mas continuava alucinando exames acadêmicos em múltiplos idiomas.

Solução: Parser com Regex podou o ruído extra das strings.

Visualizando a Arquitetura Edge AI



AI CODE



CHATBOT



AI CHIP



AI SEARCH



ARTIFICIAL
INTELLIGENCE



ROBOTICS



AI IMAGE



AI PROCESS



DEEP
LEARNING



NEURAL
NETWORK



AI WORLD



AI CONNECT

Vencendo Alucinações

O uso de **Engenharia de Prompt** aliada a **Parsers Defensivos** em Python permitiu que modelos com "vazamento de contexto" fossem utilizados em produção.

Isso prova a viabilidade técnica de SLMs mesmo quando o comportamento bruto do modelo é instável.

Limitações e Maturidade Científica


Hardware Emulado

Coleta via restrição lógica de SO. Necessita testes futuros em chipsets ARM físicos (hardware real).

Foco Computacional

A etapa concentrou-se no pipeline de IA. Testes de UX (Experiência de Usuário) com idosos reais são o próximo passo.

Próximos Passos (Mestrado)



Obrigado!

Dúvidas e Discussão?

Agentes Conversacionais Offline para Inclusão Digital

`marcos.guida2@estudante.ufla.br`

Image Sources



http://getjubileetv.com/cdn/shop/articles/img-1755987408538_b67518d7-93cc-463f-9171-8b2324f9b2b3.png?v=1767107607

Source: getjubileetv.com



Thumbnail for

<https://masterbundles.com/wp-content/uploads/2026/01/ai-icons-603.png>

Source: masterbundles.com